

Université de Nouakchott Al-Aasriya (UNA)

جامعة نواكشوط العصرية

Faculté des Sciences et Techniques

Master en Traitement Automatique des Langues / Informatique



Analyse automatique du sentiment des avis citoyens en hassaniya et en pulaar

*Étude comparative de méthodes classiques et de Transformers multilingues pour deux langues
peu dotées*

Réalisé par :

Khadijetou Sow

Matricule : C17879

Année universitaire 2025 – 2026

Table des matières

Résumé.....	3
1. Introduction.....	3
1.1 Contexte et motivation.....	3
1.2 Problématique.....	3
1.3 Objectifs.....	4
2. État de l'art.....	4
2.1 L'analyse de sentiment.....	4
2.2 Transformers et apprentissage par transfert.....	4
2.3 Modèles spécialisés.....	4
3. Présentation du corpus.....	4
3.1 Structure et volumétrie.....	4
3.2 Annotation et limites des données.....	5
4. Méthodologie.....	5
4.1 Prétraitement et organisation des données.....	5
4.2 Les quatre approches comparées.....	5
4.3 Entraînement et évaluation.....	6
5. Résultats.....	6
5.1 Comparaison globale des approches.....	6
5.2 Résultats par langue.....	6
5.3 Détail par classe du système combiné.....	7
6. Discussion.....	7
7. Limites et perspectives.....	8
8. Conclusion.....	8
Références bibliographiques.....	8

Résumé

Ce projet conçoit et évalue un système d'analyse automatique du sentiment pour des avis de citoyens rédigés en hassaniya ou en pulaar, classés en trois catégories : positif, neutre et négatif. Ces deux langues, largement parlées en Mauritanie, sont très peu dotées en ressources informatiques et reposent sur deux systèmes d'écriture différents (arabe pour le hassaniya, latin pour le pulaar), ce qui constitue un défi de traitement à part entière.

La contribution centrale est une étude comparative de quatre approches sur un même corpus de 549 énoncés annotés : une méthode classique de référence (TF-IDF associé à une régression logistique), un Transformer multilingue générique (mBERT), et deux Transformers spécialisés par langue (MARBERT pour le hassaniya, AfroXLMR pour le pulaar) combinés en un système bilingue. Le protocole expérimental met l'accent sur la rigueur : découpage des données au niveau de l'énoncé pour éviter toute fuite entre langues, pondération des classes, et évaluation par la F-mesure macro, globalement et par langue.

Principal résultat : sur ce corpus restreint, la méthode classique obtient la meilleure F-mesure macro (0,51), devant le système à deux modèles spécialisés (0,43) et le modèle générique mBERT (0,40). Ce résultat, contre-intuitif en apparence, s'explique par le surapprentissage des grands modèles face au faible volume de données, et souligne la nécessité d'un corpus plus important avant que les approches neuronales ne deviennent avantageuses.

Mots-clés : analyse de sentiment, traitement automatique des langues, langues peu dotées, hassaniya, pulaar, BERT, MARBERT, AfroXLMR, apprentissage par transfert.

1. Introduction

1.1 Contexte et motivation

Les collectivités et administrations reçoivent un volume croissant d'avis citoyens via les réseaux sociaux et les plateformes en ligne. Leur traitement manuel est lent et coûteux. L'analyse de sentiment, sous-domaine du traitement automatique des langues (TAL), permet d'automatiser le tri de ces messages selon la polarité exprimée. Cependant, les outils existants ciblent essentiellement des langues bien dotées, et non les langues locales réellement employées par les citoyens.

En Mauritanie, le hassaniya (dialecte arabe) et le pulaar (langue peule) dominent les échanges quotidiens. Tous deux souffrent d'une rareté de données annotées et d'une orthographe peu standardisée, et leur cohabitation impose de traiter simultanément l'écriture arabe et l'écriture latine.

1.2 Problématique

La question directrice est la suivante : à partir d'un corpus de taille modeste, quelle approche permet de classer le mieux le sentiment d'avis bilingues hassaniya / pulaar ? Plus précisément, les modèles de langue pré-entraînés, génériques ou spécialisés, apportent-ils un gain réel par rapport à une méthode classique sur un volume de données limité ?

1.3 Objectifs

- Constituer et préparer un corpus de sentiment annoté pour le hassaniya et le pulaar.
- Mettre en place une chaîne complète : prétraitement, tokenisation, entraînement, évaluation.
- Comparer rigoureusement quatre approches sur un protocole identique.
- Évaluer les performances globalement et séparément par langue.
- Proposer une interface de démonstration bilingue.

2. État de l'art

2.1 L'analyse de sentiment

L'analyse de sentiment vise à déterminer l'attitude exprimée dans un texte. Les approches classiques reposent sur des représentations en sacs de mots, comme le TF-IDF, associées à des classifieurs linéaires (régression logistique, machines à vecteurs de support). Simples et robustes, elles restent des références pertinentes, notamment lorsque les données sont rares.

2.2 Transformers et apprentissage par transfert

L'architecture Transformer (Vaswani et al., 2017) a transformé le TAL grâce au mécanisme d'attention. Le modèle BERT (Devlin et al., 2019) a popularisé l'apprentissage par transfert : un modèle pré-entraîné sur de grands corpus est ensuite réajusté sur une tâche cible. Sa variante multilingue, mBERT, couvre une centaine de langues et autorise un transfert inter-langues, précieux pour les langues peu dotées (Pires et al., 2019).

2.3 Modèles spécialisés

Pour l'arabe et ses dialectes, MARBERT (Abdul-Mageed et al., 2021) est entraîné sur de grands volumes de textes dialectaux et convient au hassaniya. Pour les langues africaines, AfroXLMR (Alabi et al., 2022), fondé sur XLM-R, est adapté à de nombreuses langues du continent ainsi qu'à l'arabe ; il gère l'écriture latine du pulaar. Ces deux modèles sont les candidats naturels d'une approche spécialisée par langue.

3. Présentation du corpus

3.1 Structure et volumétrie

Le corpus est un fichier tabulaire de 793 lignes. Il est parallèle : chaque ligne contient un même énoncé décliné en hassaniya (écriture arabe et version normalisée), en pulaar lorsqu'il est disponible, et en anglais, avec une étiquette de sentiment. Après filtrage des lignes effectivement annotées, 549 énoncés sont exploitables. Tous disposent d'une version en hassaniya ; 335 disposent en outre d'une version en pulaar.

Classe	Effectif	Proportion
Neutre	227	41,3 %
Négatif	189	34,4 %

Positif	133	24,2 %
Total annoté	549	100 %

La classe majoritaire (neutre) représente environ 1,7 fois la classe minoritaire (positif). Ce déséquilibre justifie l'emploi de poids de classe et le choix de la F-mesure macro, qui pondère également chaque classe.

3.2 Annotation et limites des données

L'annotation a été réalisée manuellement sur les 549 énoncés retenus. Les 244 lignes restantes, non annotées, constituent une réserve mobilisable ultérieurement. Aucune mesure d'accord inter-annotateurs n'a été calculée, ce qui constitue une limite à mentionner. Les énoncés étant courts, la longueur maximale de séquence a été fixée à 64 sous-unités lors de la tokenisation.

4. Méthodologie

4.1 Prétraitement et organisation des données

Le prétraitement comprend la sélection des lignes annotées, la normalisation des étiquettes et leur conversion numérique (négatif = 0, neutre = 1, positif = 2), ainsi que la suppression des textes vides. Le corpus parallèle est ensuite réorganisé par empilement vertical : chaque énoncé donne un exemple distinct par langue disponible, ce qui reflète un usage réel où un citoyen s'exprime dans une seule langue.

Le découpage en ensembles d'entraînement, de validation et de test (80 / 10 / 10) est effectué au niveau de l'énoncé, avant le dédoublement par langue, et stratifié selon le sentiment. Ainsi, les différentes versions linguistiques d'un même énoncé restent dans le même ensemble : sans cette précaution, la version hassaniya d'un énoncé pourrait servir à l'entraînement et sa version pulaar au test, provoquant une fuite d'information. Le découpage produit 439 énoncés d'entraînement, 55 de validation et 55 de test, communs à toutes les approches.

4.2 Les quatre approches comparées

- Référence classique : représentation TF-IDF (unigrammes et bigrammes) suivie d'une régression logistique à poids de classe équilibrés.
- Transformer générique : mBERT (bert-base-multilingual-cased) réajusté sur l'ensemble des exemples, toutes langues confondues.
- Transformer spécialisé hassaniya : MARBERT, réajusté uniquement sur les exemples en hassaniya.
- Transformer spécialisé pulaar : AfroXLMR (afro-xlmr-base), réajusté uniquement sur les exemples en pulaar.

Les deux modèles spécialisés sont ensuite combinés en un système bilingue : chaque texte est routé vers le modèle de sa langue, selon son écriture.

4.3 Entraînement et évaluation

Le réajustement utilise un taux d'apprentissage de 2×10^{-5} , des lots de 16 et un maximum de 15 époques, avec un arrêt anticipé interrompant l'entraînement lorsque la F-mesure macro de validation cesse de progresser, ce qui limite le surapprentissage. Des poids de classe inversement proportionnels aux effectifs sont intégrés à la fonction de perte. L'évaluation repose sur l'exactitude, la précision, le rappel et la F-mesure, la F-mesure macro servant de critère principal, mesurée globalement et par langue.

5. Résultats

5.1 Comparaison globale des approches

Le tableau suivant présente les performances sur l'ensemble de test combiné (82 exemples : 55 en hassaniya, 27 en pulaar), identique pour toutes les approches.

Approche	Exactitude	F1-macro
Baseline TF-IDF + Régression logistique	0,55	0,51
Système à deux modèles (MARBERT + AfroXLMR)	0,50	0,43
mBERT (mono-modèle)	0,41	0,40




Figure 1 — F-mesure macro par approche sur le test combiné.

La méthode classique obtient la meilleure F-mesure macro (0,51). Le système à deux modèles spécialisés (0,43) devance le modèle générique mBERT (0,40), ce qui confirme l'intérêt de spécialiser par langue, mais aucune approche neuronale n'atteint le niveau de la référence.

5.2 Résultats par langue

L'analyse par langue oppose, pour chaque langue, la référence classique au Transformer spécialisé correspondant.

Langue	Baseline	Transformer	n (test)
--------	----------	-------------	----------

		spécialisé	
Hassaniya	0,36	MARBERT : 0,34	55
Pulaar	0,72	AfroXLMR : 0,60	27




Figure 2 — Comparaison baseline / Transformer spécialisé, par langue.

Dans les deux langues, le Transformer spécialisé ne dépasse pas la référence. L'écart est faible en hassaniya (0,34 contre 0,36) mais net en pulaar (0,60 contre 0,72). On observe par ailleurs une forte asymétrie entre langues : le pulaar est nettement mieux classé que le hassaniya, quelle que soit la méthode. Le test pulaar ne comptant que 27 exemples, ces valeurs restent toutefois bruitées.

5.3 Détail par classe du système combiné

Classe	Précision	Rappel	F1
Négatif	0,48	0,52	0,50
Neutre	0,57	0,68	0,62
Positif	0,22	0,12	0,15

La classe positif est le maillon faible de toutes les approches (F1 = 0,15 pour le système combiné). En hassaniya, MARBERT ne prédit correctement aucun exemple positif (F1 = 0,00). Cette défaillance s'explique par la rareté de cette classe (133 exemples seulement) combinée au surapprentissage des modèles.

6. Discussion

Le constat dominant est que, sur ce corpus, les Transformers ne surpassent pas une méthode classique. Trois éléments l'expliquent.

D'abord, le surapprentissage. Les courbes d'entraînement le montrent clairement : pour MARBERT, la perte d'entraînement chute jusqu'à 0,03 tandis que la perte de validation grimpe

au-delà de 2,0 ; le même phénomène s'observe pour mBERT. Avec quelques centaines d'exemples seulement, ces grands modèles mémorisent les données d'entraînement sans généraliser, alors que la régression logistique, plus simple, reste robuste.

Ensuite, l'asymétrie entre langues. Le pulaar est systématiquement mieux classé que le hassaniya. Plusieurs facteurs peuvent y contribuer : la complexité morphologique de l'arabe dialectal, la variabilité orthographique du hassaniya, et la taille réduite de l'échantillon de test pulaar, qui peut surévaluer la performance.

Enfin, le déséquilibre des classes. Malgré la pondération, la classe positif demeure mal reconnue, faute d'exemples suffisants. C'est la première piste d'amélioration concrète : enrichir cette classe.

Ce résultat n'est pas un échec, mais une conclusion instructive : il quantifie le seuil de données en deçà duquel les approches neuronales ne sont pas rentables pour ces langues, et oriente les travaux futurs vers la constitution de corpus plus vastes.

7. Limites et perspectives

La principale limite est la taille du corpus (549 énoncés annotés), qui restreint la performance atteignable et rend les estimations sensibles au découpage ; une validation croisée stabiliserait les chiffres. S'y ajoutent le déséquilibre des classes et l'absence d'accord inter-annotateurs.

Les perspectives sont claires. À court terme : annoter les 244 énoncés disponibles, renforcer la classe positif, et appliquer une validation croisée. À moyen terme : explorer l'augmentation de données (par traduction ou paraphrase), et déployer en production la méthode la plus performante observée, à savoir la référence classique, en attendant un corpus suffisant pour les approches neuronales.

8. Conclusion

Ce projet a conçu une chaîne complète d'analyse de sentiment bilingue pour le hassaniya et le pulaar, et comparé quatre approches sur un protocole rigoureux. Le résultat principal est que, sur un corpus restreint et peu doté, une méthode classique (TF-IDF et régression logistique) surpasse aussi bien un Transformer générique que des modèles spécialisés, ces derniers souffrant de surapprentissage. La spécialisation par langue améliore néanmoins le système neuronal et reste prometteuse à plus grande échelle. Au-delà des performances, le travail livre une méthodologie soignée — organisation d'un corpus parallèle, découpage sans fuite, évaluation par langue — et une feuille de route précise pour le traitement automatique des langues mauritaniennes.

Références bibliographiques

- [1] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. NeurIPS.
- [2] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT.
- [3] Pires, T., Schlinger, E., & Garrette, D. (2019). How Multilingual is Multilingual BERT? ACL.

- [4] Conneau, A., Khandelwal, K., Goyal, N., et al. (2020). Unsupervised Cross-lingual Representation Learning at Scale (XLM-R). ACL.
- [5] Abdul-Mageed, M., Elmadany, A., & Nagoudi, E. M. B. (2021). ARBERT & MARBERT: Deep Bidirectional Transformers for Arabic. ACL.
- [6] Alabi, J. O., Adelani, D. I., Mosbach, M., & Klakow, D. (2022). Adapting Pre-trained Language Models to African Languages via Multilingual Adaptive Fine-Tuning (AfroXLMR). COLING.
- [7] Wolf, T., Debut, L., Sanh, V., et al. (2020). Transformers: State-of-the-Art Natural Language Processing. EMNLP (System Demonstrations).